

Étude et prévision de modèle type trafic routier à l'aide des outils du Deep Learning

Stage L3

Amer Essakine et Quentin Boiret

Encadré par : Argyris Kalogeratos et Xavier Cassagnou



école normale supérieure paris-saclay

Introduction



Les 26 voies de la Katy Freeway, Texas, États-Unis

Problématique



Figure: Réseau électrique français



Localisation du parc EPR français

Auto-regressive integrated moving average(ARIMA)

On note V_t les observations de la consommation d'énergie pour une région.

Le processus AR (Auto-régressif) suppose que V_t dépend de ses valeurs aux p instants précédents :

$$\forall t, V_t = \sum_{i=1}^p \alpha_i V_{t-i} + \epsilon_t$$

Le processus MA (Moyenne ajustée) suppose que $(V_t)_t$ est une combinaison linéaire d'erreurs aléatoires :

$$\forall t, V_t = \epsilon_t + \sum_{i=1}^q \beta_i \epsilon_{t-i}$$

ARIMA est la combinaison des deux approches :

$$\forall t, V_t = \sum_{i=1}^p \alpha_i V_{t-i} + \epsilon_t + \sum_{i=1}^q \beta_i \epsilon_{t-i}$$

Generalized Additive Models(GAM)

GAM suppose que la consommation d'énergie pour une région V est liée à des paramètres X_1, \dots, X_p selon la relation :

$$V_t = f_1(X_1) + \dots + f_p(X_p)$$

Avec f_i une fonction polynomiale par morceaux, la relation peut être exprimée sous la forme suivante :

$$f_i(X) = \sum_{j=1}^3 b_{j,i} x^j$$

Résultats des approches traditionnelles

- La métrique MAE :

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- La métrique MAPE :

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

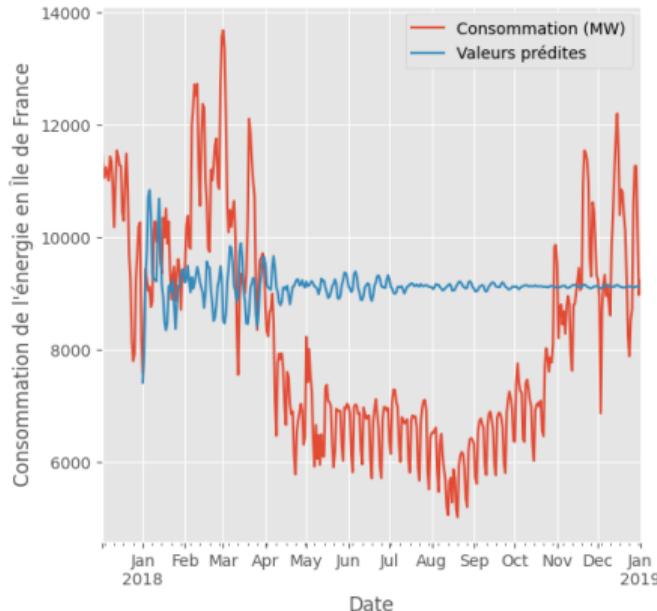
- La métrique RMSE :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Méthode	ARIMA	GAM
MAPE	26.452	1.9667
MAE	26.452	1.9667
RMSE	27.04	2.6459

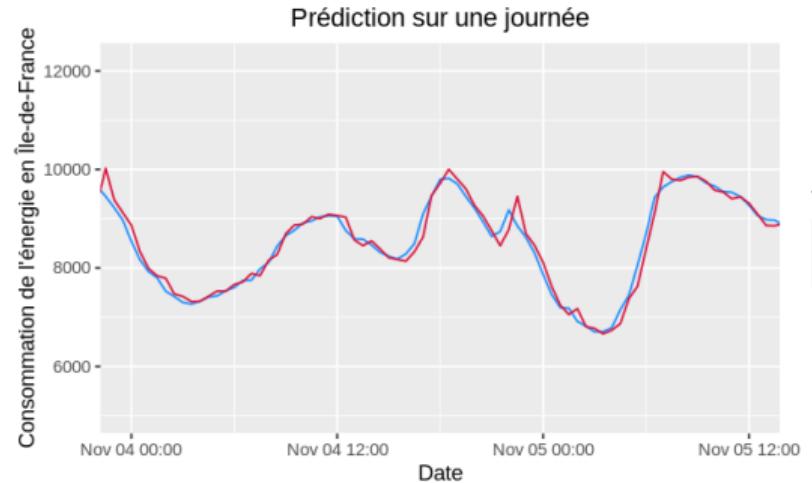

Résultats des métriques pour les méthodes GAM et ARIMA

Méthode ARIMA



Graphique des valeurs attendues (rouge) avec celles prédictes (bleu) avec la méthode ARIMA sur l'année 2018

Méthode GAM



Convolution spatiale

Définition

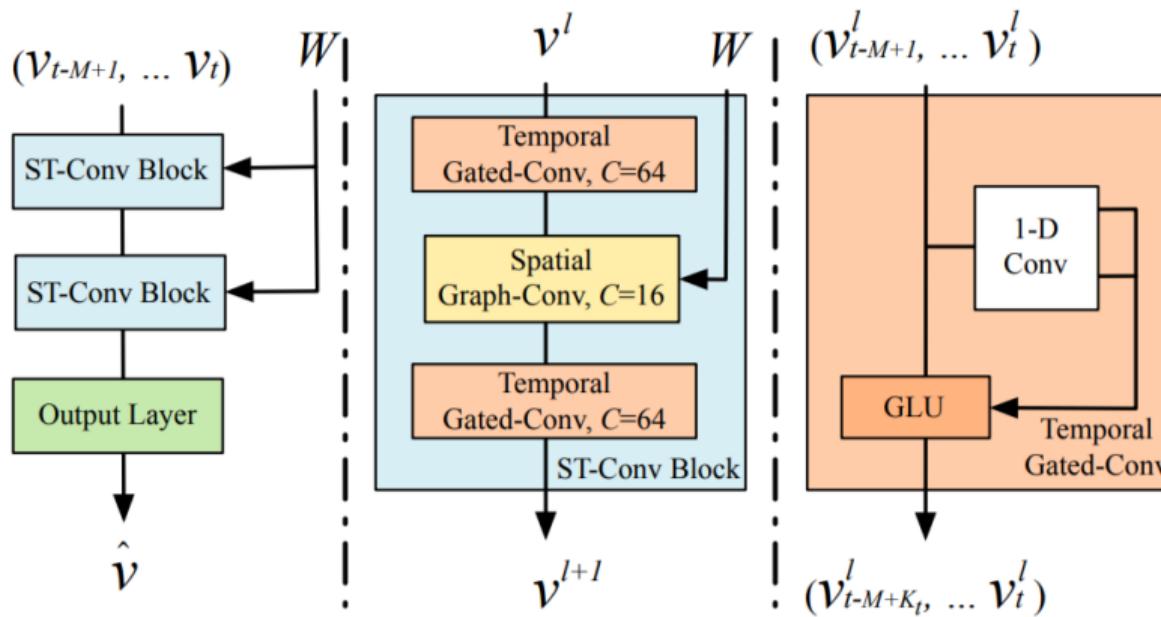
On définit l'opération de convolution sur un graphe comme la multiplication matricielle de l'entrée $x \in \mathbb{R}^N$ et du noyau $g_\theta = \text{diag}(\theta)$, paramétrisé par $\theta \in \mathbb{R}^N$, dans le domaine de Fourier.

$$g_\theta *_{\mathcal{G}} x = g_\theta(\Lambda)x = Ug_\theta U^T x \quad (1)$$

On fait une approximation à l'ordre 1 :

$$g_\theta *_{\mathcal{G}} x \approx \theta_0 x - \theta_1 (L - I_N) x \approx \theta_0 x - \theta_1 (D^{-\frac{1}{2}} W D^{\frac{1}{2}}) x \approx \theta (I_N + D^{-\frac{1}{2}} W D^{\frac{1}{2}}) x \quad (2)$$

STGCN



Architecture de la STGCN

Matrice d'adjacence

L'approche pour optimiser la matrice d'adjacence


- On cherche la matrice d'adjacence W sous la forme :

$$W = \lambda A + (1 - \lambda) Id$$


Avec $\lambda \ll 1$

- Ne garder que les nœuds qui ont les poids les plus élevés.
- Supprimer les nœuds ayant des poids très faibles.


Matrice d'adjacence



Matrice de proximité
 $\lambda = 0.0246$

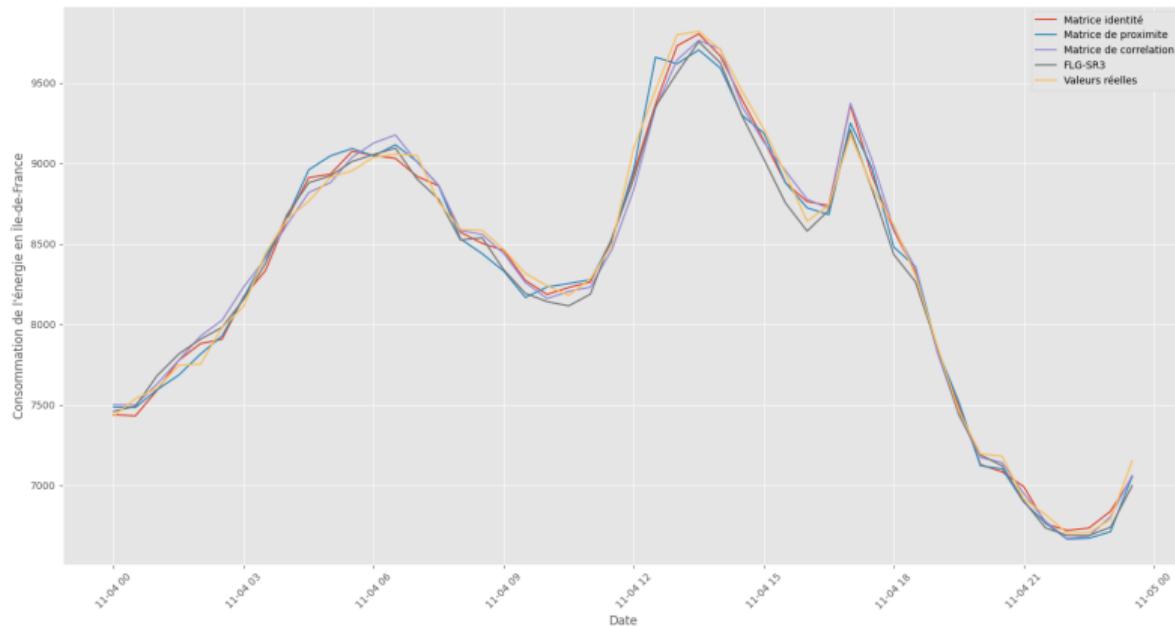


Matrice de corrélation



Matrice FGL-3SR
 $\lambda = 0.0241$


Résultats STGCN



Graphique des résultats des méthodes de deep learning sur la journée du 4 novembre

Résultats STGCN

Méthode	ARIMA	GAMs	identité	proximité	corrélation	FGL-3SR
MAPE	26.452	1.9667	1.3295	1.2571	1.2526	1.1797
MAE	26.452	1.9667	1.1777	1.1400	1.1341	1.0796
RMSE	27.04	2.6459	1.5947	1.5550	1.5641	1.4859



Graphique résumant l'erreur MAPE pour chaque région

- [1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*.
<http://www.deeplearningbook.org>. MIT Press, 2016.
- [2] Zhanxing Zhu Bing Yu Haoteng Yin. "Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting". In: (juillet 2018).
- [3] G Dreyfus et al. *Apprentissage statistique*. Springer, 2008. ISBN: 978-2-212-11464-5.
- [4] Mitchell Lyons. *generalised additive models (GAMs)*. URL:
<https://environmentalcomputing.net/statistics/gams/>.
- [5] Max Welling Thomas N. Kipf. "Semi-Supervised Classification with Graph Convolutional Networks". In: (2017).
- [6] Didier Delignières. "Séries temporelles – Modèles ARIMA". In: (Mars 2020).
- [7] Argyris Kalogeratos et al. "Learning Laplacian Matrix from Graph Signals with Sparse Spectral Representation". In: (2021).